

Informe Técnico: Sistema de Recuperación de Información Multimodal

Asignatura: ICCD753 Recuperación de Información
Institución: Escuela Politécnica Nacional (EPN) - FIS
Integrantes: Alexander Reyes y Grupo

1. Descripción del Corpus Utilizado

El sistema trabaja sobre un subconjunto representativo del dataset multimodal de e-commerce `crossingminds/shopping-queries-image-dataset` (SQID) disponible en Hugging Face. Este corpus está compuesto por metadatos de productos de e-commerce de Amazon (títulos y descripciones) enriquecidos con enlaces a sus correspondientes imágenes digitales para posibilitar búsquedas visuales y multimodales.

- Estructura del Documento: Cada producto indexado en el sistema posee el siguiente esquema estructurado de datos en formato JSON:
- `productid`: Identificador alfanumérico único del producto.
- `title`: Descripción textual corta o título comercial del producto.
- `imageurl`: Enlace HTTPS directo a la fotografía o miniatura del artículo en internet.
- Consultas de Referencia (Qrels): Para posibilitar la evaluación experimental automática, el corpus incluye un conjunto de juicios de relevancia estructurados (`qrels.json`) basados en la etiqueta de concordancia `escilabel` del dataset benchmark original (Amazon ESCI). Las etiquetas se mapean cuantitativamente a puntajes de relevancia:
- Exact (Concordancia exacta): 3 puntos.
- Substitute (Sustituto directo): 2 puntos.
- Complement (Complementario): 1 punto.
- Irrelevant (Irrelevante): 0 puntos.

2. Arquitectura General del Sistema

El sistema implementa una arquitectura modular desacoplada mediante un cliente web (Frontend) y un servidor de procesamiento semántico (Backend) comunicados a través de una API REST:



```
end

UI -->|1. Petición /api/chat| API
Feedback -->|Petición /api/feedback| API
API --> QE
QE --> CLIP
CLIP -->|Embedding| FAISS
FAISS -->|Top-10 Candidatos| RERANK
RERANK -->|Top-4 Reordenados| LLM
FeedbackDB -->|Ajuste de Scores| RERANK
LLM -->|2. Respuesta + Evidencias + Similitudes| UI
```

- Frontend (Next.js): Construido sobre React, TypeScript y Tailwind CSS. Implementa un diseño premium monocromático y una tipografía obligatoria basada en la fuente Josefin Sans. Integra un panel colapsable nativo bajo cada respuesta para la inspección visual de las evidencias (títulos, miniaturas de imágenes y porcentajes de similitud).
- Backend (FastAPI): Proceso en Python que orquesta el pipeline de recuperación vectorial semántica y generación. Utiliza FAISS como motor de indexación de vectores y la API de Google Gemini como modelo generativo.

3. Pipeline de Recuperación y Generación (RAG)

El flujo de procesamiento de una consulta se ejecuta a través de los siguientes pasos secuenciales:

1. Expansión de Consulta (Query Expansion): La consulta cruda del usuario se procesa con Gemini para expandir términos afines (sinónimos de comercio y variaciones de marca).
2. Generación de Embeddings Multimodales (CLIP): La consulta expandida se codifica en un vector numérico de 512 dimensiones utilizando el modelo de dos torres `clip-ViT-B-32`. Esto permite alinear semánticamente el texto del usuario con el texto y las representaciones visuales del corpus.
3. Búsqueda Vectorial Semántica (FAISS): Se calcula la similitud de coseno (producto interno de vectores con normalización L2) entre la consulta y todos los productos del corpus. Se recupera una lista inicial de los 10 productos candidatos más cercanos.
4. Re-ranking (Cross-Encoder): Los candidatos de FAISS se evalúan por pares `(consulta, títuloproducto)` mediante el modelo `cross-encoder/ms-marco-MiniLM-L-6-v2` para obtener una relevancia textual profunda y libre de las limitaciones espaciales de los embeddings de una sola torre. Se seleccionan los 4 mejores productos.
5. Generación Aumentada (RAG): Se construye un prompt de sistema inyectando el historial de la conversación (memoria) y el contexto enriquecido de los 4 productos (título, score de recuperación e ID). El modelo `gemini-2.5-flash` genera una respuesta coherente y citada basándose exclusivamente en esa información.

4. Resultados Experimentales y Análisis de Métricas

La evaluación experimental del sistema de recuperación se realizó de forma sistemática contrastando los resultados de búsqueda de FAISS contra las listas de juicios de relevancia de `qrels.json`. Se reportan las métricas académicas de Precision@k, Recall@k y NDCG@k para los umbrales típicos de recuperación (k = 1, 3, 5):

Tabla de Métricas de Recuperación Promedio

Umbral (k)	Precision@k	Recall@k	NDCG@k
k = 1	1.0000	0.4444	1.0000

k = 3	1.0000	1.0000	1.0000
k = 5	0.6000	1.0000	0.8938

Análisis de Desempeño:

- Precision@k: Para k=1 y k=3, el sistema mantiene una precisión perfecta (1.0000), indicando que todos los productos devueltos en las primeras posiciones son altamente relevantes para la necesidad de información del usuario. Al ampliar a k=5, la precisión desciende a 0.6000, lo cual es esperado dado que se recuperan documentos menos específicos (sustitutos o complementos con etiquetas de menor puntaje).
- Recall@k: El recobrado alcanza su valor máximo (1.0000) a partir de k=3. Esto demuestra la efectividad de los embeddings de CLIP y la expansión de consultas para capturar la totalidad de los elementos relevantes de la base de datos pequeña en las primeras posiciones de respuesta.
- NDCG@k: El puntaje de ganancia acumulada descontada normalizada es perfecto (1.0000) en las posiciones más altas (k=1, 3), demostrando que el orden del ranking devuelto está perfectamente alineado con las preferencias de relevancia del qrels (colocando los productos `Exact` primero y los `Substitute` después). En k=5, el NDCG es de 0.8938, lo que ratifica la altísima fidelidad del ranking de recuperación.

5. Descripción de las Funcionalidades de Excelencia Implementadas

Para maximizar el desempeño y asegurar la nota máxima del proyecto final, se incorporaron 4 funcionalidades avanzadas:

1. Re-ranking (+15 puntos): Uso de `ms-marco-MiniLM-L-6-v2` para corregir sesgos del codificador CLIP. El reordenamiento permite que productos semánticamente idénticos suban en la lista de prioridades a pesar de variaciones léxicas en la consulta.
2. Query Expansion (+15 puntos): Gemini reescribe de forma transparente la consulta agregando sinónimos comerciales y descriptivos (ej. "running shoes" se expande a "sneakers, athletic footwear, sport shoes"). Esto ayuda a mitigar el problema del vocabulario desalineado en e-commerce.
3. Relevance Feedback (+15 puntos): Los botones de me gusta/no me gusta de la UI las notificaciones al backend de forma asíncrona. El sistema guarda este feedback en un archivo estructurado local y lo utiliza para incrementar o reducir linealmente el score de similitud de esos productos en futuras consultas similares.
4. Memoria Conversacional (+15 puntos): El frontend inyecta el historial secuencial estructurado de la sesión en el payload de `/api/chat`. El backend procesa este historial en el prompt de RAG para mantener el hilo del diálogo y resolver pronombres o referencias contextuales.