

Proyecto Final

Sistema de Recuperación de Información Multimodal con RAG

Asignatura: Recuperación de Información

Objetivo

Diseñar e implementar un sistema de **Recuperación de Información Multimodal** capaz de responder consultas conversacionales sobre un corpus compuesto por texto e imágenes.

El sistema deberá utilizar modelos de **embeddings multimodales** para representar el contenido del corpus, almacenar dichas representaciones en una base de datos vectorial, recuperar los elementos más relevantes para una consulta y utilizarlos como contexto para un sistema de *Retrieval-Augmented Generation* (RAG).

El objetivo del proyecto es integrar los conceptos estudiados durante el curso en un sistema moderno de Recuperación de Información, combinando recuperación multimodal, bases de datos vectoriales, modelos de lenguaje, interfaces conversacionales y evaluación experimental.

Modalidad de trabajo

El proyecto se desarrollará en los **grupos ya formados de 2 o 3 personas**. Todos los integrantes del grupo deberán conocer y poder explicar la arquitectura, el código, el pipeline de recuperación y las decisiones técnicas tomadas durante el desarrollo del sistema.

Alcance y funcionalidades mínimas

El sistema deberá cumplir con los siguientes requerimientos.

a. Preparación del corpus

El sistema deberá trabajar sobre un **corpus multimodal** compuesto por documentos que incluyan información textual e imágenes.

El grupo deberá:

- cargar el corpus;
- procesar el texto cuando sea necesario;
- asociar correctamente cada imagen con la información textual correspondiente.

b. Construcción de representaciones vectoriales

El sistema deberá utilizar un modelo multimodal basado en **CLIP** para generar embeddings.

Deberá:

- generar embeddings para todos los documentos del corpus;

- generar embeddings para las consultas del usuario;
- almacenar las representaciones vectoriales para su recuperación posterior.

c. Base de datos vectorial

El sistema deberá utilizar una base de datos vectorial, como **FAISS** o **ChromaDB**, para almacenar e indexar los embeddings.

Deberá permitir:

- indexar el corpus;
- recuperar los documentos más similares para una consulta;
- obtener un ranking *Top-k* de resultados.

d. Sistema RAG

El sistema deberá implementar un flujo de *Retrieval-Augmented Generation* (RAG).

El pipeline mínimo será:

1. recibir una consulta del usuario;
2. recuperar los documentos más relevantes mediante búsqueda vectorial;
3. construir automáticamente el contexto para el modelo de lenguaje;
4. generar una respuesta utilizando dicho contexto.

Visualización de evidencias. Además de la respuesta generada, el sistema **deberá mostrar las evidencias utilizadas para construir dicha respuesta.**

Como mínimo, la interfaz deberá presentar:

- los documentos recuperados (*Top-k*);
- las imágenes asociadas, cuando existan;
- el puntaje o similitud de recuperación de cada resultado.

El usuario deberá poder inspeccionar las evidencias utilizadas por el sistema para verificar el origen de la información empleada en la generación de la respuesta.

El objetivo de este requisito es garantizar la transparencia y trazabilidad del sistema RAG, permitiendo distinguir claramente entre el proceso de recuperación y el proceso de generación.

e. Interfaz conversacional

El sistema deberá disponer de una **interfaz web básica tipo chat.**

Como mínimo deberá permitir:

- realizar consultas conversacionales;
- visualizar la respuesta del asistente;
- visualizar los documentos e imágenes utilizados como contexto por el sistema RAG.

Se permite incorporar funcionalidades adicionales, como búsqueda por voz o carga de imágenes, aunque no constituyen un requisito obligatorio.

f. Evaluación del sistema

El sistema deberá evaluarse utilizando un conjunto de consultas y documentos relevantes (*qrels*).

Como mínimo deberán reportarse las siguientes métricas:

- Precision@k;
- Recall@k;
- NDCG@k.

El informe deberá incluir un análisis de los resultados obtenidos y una discusión sobre el comportamiento del sistema.

Funcionalidades de excelencia

Además del sistema base, el grupo podrá implementar una o más funcionalidades avanzadas. Cada funcionalidad correctamente implementada otorgará **15 puntos adicionales**, hasta alcanzar la nota máxima del proyecto.

Re-ranking (+15)

Implementar un modelo de *re-ranking* que refine el ranking inicial obtenido mediante búsqueda vectorial antes de generar la respuesta del sistema RAG.

Query Expansion (+15)

Implementar un mecanismo automático de expansión o reformulación de consultas que permita mejorar la recuperación de documentos relevantes.

Relevance Feedback (+15)

Permitir que el usuario califique las respuestas o documentos recuperados mediante opciones como “Me gusta” y “No me gusta”, utilizando esta información para mejorar búsquedas posteriores.

Memoria conversacional (+15)

Implementar memoria de conversación para que el sistema utilice el contexto de interacciones anteriores durante la recuperación y generación de respuestas.

Requisitos técnicos

- Lenguaje sugerido: **Python**.
- Se podrán utilizar bibliotecas como:
 - PyTorch;

- Transformers;
 - OpenCLIP;
 - sentence-transformers;
 - FAISS;
 - ChromaDB;
 - LangChain o LlamaIndex;
 - Streamlit, Gradio o Flask para la interfaz web.
- El modelo CLIP podrá ser cualquier variante preentrenada disponible públicamente.
 - Se podrá utilizar cualquier modelo de lenguaje accesible mediante API o ejecución local para implementar el componente RAG.
 - No se permite utilizar motores completos de búsqueda como **Elasticsearch**, **OpenSearch**, **Solr** o sistemas equivalentes que oculten el proceso de recuperación.

Entregables

Los grupos deberán entregar:

1. Código fuente completo del proyecto.
2. Archivo **README** con instrucciones claras para la instalación y ejecución.
3. Informe técnico de máximo **5 páginas**, que incluya:
 - descripción del corpus utilizado;
 - arquitectura general del sistema;
 - descripción del pipeline de recuperación y generación;
 - resultados experimentales;
 - análisis de las métricas de evaluación;
 - descripción de las funcionalidades de excelencia implementadas, si las hubiera.
4. Video demostrativo de máximo **5 minutos**, mostrando el funcionamiento completo del sistema.

Criterios de evaluación

Sistema base

Criterio	Puntaje
Preparación del corpus	10
Generación de embeddings con CLIP	10
Implementación de la base de datos vectorial (FAISS o ChromaDB)	10
Recuperación multimodal	10
Implementación del sistema RAG	15
Interfaz web conversacional	5
Evaluación experimental (Precision@k, Recall@k y NDCG@k)	10
Total sistema base	70

Funcionalidades de excelencia

Funcionalidad	Puntaje
Re-ranking	+15
Query Expansion	+15
Relevance Feedback	+15
Memoria conversacional	+15

La nota máxima del proyecto será de **100 puntos**, independientemente de que la suma de puntos obtenidos en el sistema base y las funcionalidades de excelencia exceda dicho valor.

Consideraciones finales

- El proyecto se desarrollará en los grupos ya formados de **2 o 3 personas**.
- El sistema deberá ser completamente funcional y reproducible siguiendo las instrucciones incluidas en el archivo **README**.
- El uso de herramientas de Inteligencia Artificial para asistir en el desarrollo del proyecto está permitido. Sin embargo, los estudiantes deberán comprender y poder explicar el funcionamiento de todos los componentes implementados.
- Durante la presentación del proyecto, el docente podrá solicitar modificaciones, ejecutar consultas adicionales o realizar preguntas sobre cualquier parte de la implementación para verificar la autoría y comprensión del trabajo.